



Universidade Federal de Rio Grande do Norte  
Centro de Ciências Exatas e da Terra  
Programa de Pós-Graduação em Matemática Aplicada e Estatística

## **Take Home - Séries Temporais**

Wyara Moura

Professor: André Luís Santos de Pinho

Natal, RN  
2015

# Sumário

1	Questão 1	3
2	Questão 2	8
3	Questão 3	10
4	Anexo I	15

# 1 Questão 1

Considerando o processo  $\{Y_t\}$  abaixo, será verificado se tal processo é estacionário segundo algumas condições especificadas na questão.

$$Y_t = \phi^t Y_0 + \sum_{i=0}^{t-1} \phi^i \varepsilon_{t-i}, \quad t = 1, 2, \dots$$

Primeiro caso, quando:  $Y_0 = 0$  e  $\phi$  uma constante satisfazendo  $|\phi| < 1$ . Em que também,  $\{\varepsilon_t\}$  é um processo de ruído branco forte. com média 0 e variância  $\sigma_\varepsilon^2$ . Para verificar se o processo é ou não estacionário, serão calculados a esperança e as autocovariâncias do modelo, para verificar se existe dependência do período  $t$ .

Cálculo da esperança:

$$\begin{aligned} E(Y_t) &= E\left(\phi^t Y_0 + \sum_{i=0}^{t-1} \phi^i \varepsilon_{t-i}\right) \\ &= E(\phi^0 \varepsilon_{t-0} + \phi^1 \varepsilon_{t-1} + \phi^2 \varepsilon_{t-2} + \dots + \phi^{t-3} \varepsilon_3 + \phi^{t-2} \varepsilon_2 + \phi^{t-1} \varepsilon_1) \\ &= 0 + \phi E(\varepsilon_{t-1}) + \phi^2 E(\varepsilon_{t-2}) + \dots + \phi^{t-3} E(\varepsilon_3) + \phi^{t-2} E(\varepsilon_2) + \phi^{t-1} E(\varepsilon_1) \\ &= 0 + \phi \times 0 + \phi^2 \times 0 + \dots + \phi^{t-3} \times 0 + \phi^{t-2} \times 0 + \phi^{t-1} \times 0 \\ &= 0 \end{aligned}$$

Assim, observa-se que a esperança do processo  $\{Y_t\}$  não depende de  $t$ , mas não é condição suficiente para concluir se a série é ou não estacionária.

Cálculo das autocovariâncias ( $\gamma(s)$ ):

$$\gamma(s) = \text{cov}(Y_t, Y_{t+s}) = \text{cov}\left(\phi^t Y_0 + \sum_{i=0}^{t-1} \phi^i \varepsilon_{t-i}, \phi^{t+s} Y_0 + \sum_{i=0}^{t+s-1} \phi^i \varepsilon_{t+s-i}\right)$$

em que desenvolvendo, tem-se  $Y_t$  igual a:

$$\begin{aligned} Y_t &= \phi^0 Y_0 + \phi^0 \varepsilon_{t-0} + \phi^1 \varepsilon_{t-1} + \phi^2 \varepsilon_{t-2} + \dots + \phi^{t-3} \varepsilon_{t-(t-3)} + \phi^{t-2} \varepsilon_{t-(t-2)} + \phi^{t-1} \varepsilon_{t-(t-1)} \\ &= \phi^0 \varepsilon_{t-0} + \phi^1 \varepsilon_{t-1} + \phi^2 \varepsilon_{t-2} + \dots + \phi^{t-3} \varepsilon_3 + \phi^{t-2} \varepsilon_2 + \phi^{t-1} \varepsilon_1 \end{aligned}$$

Assim,

$$\begin{aligned}
\text{cov}(Y_t, Y_{t+s}) &= \text{cov} \left( \begin{array}{l} \varepsilon_t + \phi^1 \varepsilon_{t-1} + \phi^2 \varepsilon_{t-2} + \cdots + \phi^{t-3} \varepsilon_3 + \phi^{t-2} \varepsilon_2 + \phi^{t-1} \varepsilon_1, \\ \varepsilon_{t+s} + \phi^1 \varepsilon_{t+s-1} + \phi^2 \varepsilon_{t+s-2} + \cdots + \phi^{t+s-3} \varepsilon_3 + \phi^{t+s-2} \varepsilon_2 + \phi^{t+s-1} \varepsilon_1 \end{array} \right) \\
(1) \quad &= \text{cov}(\varepsilon_t, \varepsilon_{t+s}) + \phi \text{cov}(\varepsilon_t, \varepsilon_{t+s-1}) + \phi^2 \text{cov}(\varepsilon_t, \varepsilon_{t+s-2}) + \cdots + \\
&\quad + \phi^{t+s-3} \text{cov}(\varepsilon_t, \varepsilon_3) + \phi^{t+s-2} \text{cov}(\varepsilon_t, \varepsilon_2) + \phi^{t+s-1} \text{cov}(\varepsilon_t, \varepsilon_1) + \\
&\quad + \phi^1 \text{cov}(\varepsilon_{t-1}, \varepsilon_{t+s}) + \phi^2 \text{cov}(\varepsilon_{t-1}, \varepsilon_{t+s-1}) + \phi^3 \text{cov}(\varepsilon_{t-1}, \varepsilon_{t+s-2}) + \cdots + \\
&\quad + \phi^{t+s-2} \text{cov}(\varepsilon_{t-1}, \varepsilon_3) + \phi^{t+s-1} \text{cov}(\varepsilon_{t-1}, \varepsilon_2) + \phi^{t+s} \text{cov}(\varepsilon_{t-1}, \varepsilon_1) + \\
&\quad \vdots \\
&\quad + \phi^{t-2} \text{cov}(\varepsilon_2, \varepsilon_{t+s}) + \phi^{t-1} \text{cov}(\varepsilon_2, \varepsilon_{t+s-1}) + \phi^t \text{cov}(\varepsilon_2, \varepsilon_{t+s-2}) + \cdots + \\
&\quad + \phi^{2(t-2)-1+s} \text{cov}(\varepsilon_2, \varepsilon_3) + \phi^{2(t-2)+s} \text{cov}(\varepsilon_2, \varepsilon_2) + \phi^{2(t-2)+1+s} \text{cov}(\varepsilon_2, \varepsilon_1) + \\
&\quad + \phi^{t-1} \text{cov}(\varepsilon_1, \varepsilon_{t+s}) + \phi^t \text{cov}(\varepsilon_1, \varepsilon_{t+s-1}) + \phi^{t+1} \text{cov}(\varepsilon_1, \varepsilon_{t+s-2}) + \cdots + \\
&\quad + \phi^{2(t-1)-2+s} \text{cov}(\varepsilon_1, \varepsilon_3) + \phi^{2(t-1)-1+s} \text{cov}(\varepsilon_1, \varepsilon_2) + \phi^{2(t-1)+s} \text{cov}(\varepsilon_1, \varepsilon_1)
\end{aligned}$$

Fazendo para o caso de  $s = 0$ , e levando em conta que  $\text{var}(\varepsilon_t) = \sigma_\varepsilon^2$

$$\begin{aligned}
\gamma(0) = \text{cov}(Y_t, Y_t) &= \text{cov}(\varepsilon_t, \varepsilon_t) + \phi^2 \text{cov}(\varepsilon_{t-1}, \varepsilon_{t-1}) + \phi^4 \text{cov}(\varepsilon_{t-2}, \varepsilon_{t-2}) + \cdots + \\
&\quad + \phi^{2(t-3)} \text{cov}(\varepsilon_3, \varepsilon_3) + \phi^{2(t-2)} \text{cov}(\varepsilon_2, \varepsilon_2) + \phi^{2(t-1)} \text{cov}(\varepsilon_1, \varepsilon_1) + \\
&= \sigma_\varepsilon^2 + \phi^2 \sigma_\varepsilon^2 + \phi^4 \sigma_\varepsilon^2 + \cdots + \\
&\quad + \phi^{2(t-3)} \sigma_\varepsilon^2 + \phi^{2(t-2)} \sigma_\varepsilon^2 + \phi^{2(t-1)} \sigma_\varepsilon^2 \\
&= \sigma_\varepsilon^2 [1 + \phi^2 + \phi^4 + \cdots + \phi^{2(t-3)} + \phi^{2(t-2)} + \phi^{2(t-1)}] \\
(2) \quad &= \sigma_\varepsilon^2 \left[ \sum_{i=0}^{t-1} \phi^{2i} \right]
\end{aligned}$$

$s = 1$

$$\begin{aligned}
\gamma(1) = \text{cov}(Y_t, Y_{t+1}) &= \phi \text{cov}(\varepsilon_t, \varepsilon_t) + \phi^3 \text{cov}(\varepsilon_{t-1}, \varepsilon_{t-1}) + \phi^5 \text{cov}(\varepsilon_{t-2}, \varepsilon_{t-2}) + \cdots + \\
&\quad + \phi^{2(t-3)+1} \text{cov}(\varepsilon_3, \varepsilon_3) + \phi^{2(t-2)+1} \text{cov}(\varepsilon_2, \varepsilon_2) + \phi^{2(t-1)+1} \text{cov}(\varepsilon_1, \varepsilon_1) \\
&= \phi \sigma_\varepsilon^2 + \phi^3 \sigma_\varepsilon^2 + \phi^5 \sigma_\varepsilon^2 + \cdots + \\
&\quad + \phi^{2(t-3)+1} \sigma_\varepsilon^2 + \phi^{2(t-2)+1} \sigma_\varepsilon^2 + \phi^{2(t-1)+1} \sigma_\varepsilon^2 \\
&= \sigma_\varepsilon^2 [\phi + \phi^3 + \phi^5 + \cdots + \phi^{2(t-3)+1} + \phi^{2(t-2)+1} + \phi^{2(t-1)+1}] \\
(3) \quad &= \sigma_\varepsilon^2 \left[ \sum_{i=0}^{t-1} \phi^{2i+1} \right]
\end{aligned}$$

$s = 2$

$$\begin{aligned}
\gamma(2) = \text{cov}(Y_t, Y_{t+2}) &= \phi^2 \text{cov}(\varepsilon_t, \varepsilon_t) + \phi^4 \text{cov}(\varepsilon_{t-1}, \varepsilon_{t-1}) + \phi^6 \text{cov}(\varepsilon_{t-2}, \varepsilon_{t-2}) + \cdots + \\
&\quad + \phi^{2(t-3)+2} \text{cov}(\varepsilon_3, \varepsilon_3) + \phi^{2(t-2)+2} \text{cov}(\varepsilon_2, \varepsilon_2) + \phi^{2(t-1)+2} \text{cov}(\varepsilon_1, \varepsilon_1) \\
&= \phi^2 \sigma_\varepsilon^2 + \phi^4 \sigma_\varepsilon^2 + \phi^6 \sigma_\varepsilon^2 + \cdots + \\
&\quad + \phi^{2(t-3)+2} \sigma_\varepsilon^2 + \phi^{2(t-2)+2} \sigma_\varepsilon^2 + \phi^{2(t-1)+2} \sigma_\varepsilon^2 \\
&= \sigma_\varepsilon^2 [\phi^2 + \phi^4 + \phi^6 + \cdots + \phi^{2(t-3)+2} + \phi^{2(t-2)+2} + \phi^{2(t-1)+2}] \\
&= \sigma_\varepsilon^2 \left[ \sum_{i=0}^{t-1} \phi^{2i+2} \right]
\end{aligned}$$

Portanto, tem-se como formula geral para todo  $s \geq 0$ ,

$$\gamma(s) = \text{cov}(Y_t, Y_{t+s}) = \sigma_\varepsilon^2 \left[ \sum_{i=0}^{t-1} \phi^{2i+s} \right]$$

Observando então, que o processo  $\{Y_t\}$  não é estacionário, pois as autocovariâncias dependem do valor de  $t$ . Agora, será mostrado que para valores grandes de  $t$  a dependência em  $t$  das autocovariâncias é negligenciável.

Para isso, primeiramente observa-se que,

$$\left[ \sum_{i=0}^{t-1} \phi^{2i+s} \right]$$

é uma progressão geométrica com razão dada por,

$$q = \frac{\phi^{2+s}}{\phi^s} = \phi^2$$

em que a soma dessa progressão geométrica é,

$$= \phi^s \frac{1-\phi^{2t}}{1-\phi^2} = \frac{\phi^s}{1-\phi^2} - \frac{\phi^{2t}}{1-\phi^2}$$

Aplicando então o limite, para verificar o que acontece quando o valor de  $t$  tende ao infinito,

$$\lim_{t \rightarrow \infty} \frac{\phi^s}{1-\phi^2} - \underbrace{\frac{\phi^{2t}}{1-\phi^2}}_{\text{tende para 0, pois } |\phi| < 1} = \frac{\phi^s}{\phi^2 - 1}$$

O processo  $\{Y_t\}$  pode ser escrito da forma recursiva mostrada abaixo, levando em conta que  $Y_0 = 0$ .

$$\begin{aligned}
Y_t &= \phi^t Y_0 + \sum_{i=0}^{t-1} \phi^i \varepsilon_{t-i} \\
&= \sum_{i=0}^{t-1} \phi^i \varepsilon_{t-i} \\
&= \phi^0 \varepsilon_{t-0} + \phi^1 \varepsilon_{t-1} + \phi^2 \varepsilon_{t-2} + \cdots + \phi^{t-3} \varepsilon_3 + \phi^{t-2} \varepsilon_2 + \phi^{t-1} \varepsilon_1 \\
&= \varepsilon_t + \phi^1 \varepsilon_{t-1} + \phi^2 \varepsilon_{t-2} + \cdots + \phi^{t-3} \varepsilon_3 + \phi^{t-2} \varepsilon_2 + \phi^{t-1} \varepsilon_1 \\
&= \varepsilon_t + \phi \underbrace{[\varepsilon_{t-1} + \phi \varepsilon_{t-2} + \phi^2 \varepsilon_{t-3} + \cdots + \phi^{t-4} \varepsilon_3 + \phi^{t-3} \varepsilon_2 + \phi^{t-2} \varepsilon_1]}_{Y_{t-1}} \\
Y_t &= \varepsilon_t + \phi Y_{t-1}
\end{aligned}$$

Agora para o segundo caso, quando:  $Y_0 \neq 0$  e  $\phi$  uma constante satisfazendo  $|\phi| < 1$ . Em que também,  $\{\varepsilon_t\}$  é um processo de ruído branco forte.

Cálculo da esperança:

$$\begin{aligned}
E(Y_t) &= E\left(\phi^t Y_0 + \sum_{i=0}^{t-1} \phi^i \varepsilon_{t-i}\right) \\
&= E(\phi^t Y_0 + \phi^0 \varepsilon_{t-0} + \phi^1 \varepsilon_{t-1} + \phi^2 \varepsilon_{t-2} + \cdots + \phi^{t-3} \varepsilon_3 + \phi^{t-2} \varepsilon_2 + \phi^{t-1} \varepsilon_1) \\
&= 0 + \phi^t E(Y_0) + E(\varepsilon_t) + \phi E(\varepsilon_{t-1}) + \phi^2 E(\varepsilon_{t-2}) + \cdots + \phi^{t-3} E(\varepsilon_3) + \phi^{t-2} E(\varepsilon_2) + \phi^{t-1} E(\varepsilon_1) \\
&= 0
\end{aligned}$$

A esperança do processo, não depende de  $t$ , mas não é condição necessária para concluir se a série é ou não estacionária.

O cálculo das autocovariâncias ( $\gamma(s)$ ) será:

$$\begin{aligned}
\text{cov}(Y_t, Y_{t+s}) &= \text{cov}\left(\begin{array}{l} \phi^t Y_0 + \varepsilon_t + \phi^1 \varepsilon_{t-1} + \phi^2 \varepsilon_{t-2} + \cdots + \phi^{t-3} \varepsilon_3 + \phi^{t-2} \varepsilon_2 + \phi^{t-1} \varepsilon_1, \\ \phi^{t+s} Y_0 + \varepsilon_{t+s} + \phi^1 \varepsilon_{t+s-1} + \phi^2 \varepsilon_{t+s-2} + \cdots + \phi^3 \varepsilon_{s+3} + \phi^2 \varepsilon_{s+2} + \phi^{t-1} \varepsilon_{s+1} \end{array}\right) \\
&= \phi^t \phi^{t+s} \text{cov}(Y_0, Y_0) + (1)
\end{aligned}$$

Fazendo para o caso de  $s = 0$  (assim como foi feito no primeiro caso), em que tem-se  $\text{var}(\varepsilon_t) = \sigma_\varepsilon^2$  e  $\text{var}(Y_0) = \frac{\sigma^2}{1-\phi^2}$ . Como foi estabelecido que  $\sigma^2$  que aparece na variância de  $Y_0$ , é igual a  $\text{var}(\varepsilon_t)$ , então a partir daqui, será utilizado apenas  $\sigma^2$ .

$$\begin{aligned}
\text{cov}(Y_t, Y_t) &= \phi^{2t} \text{cov}(Y_0, Y_0) + (2) \\
&= \phi^{2t} \frac{\sigma^2}{1-\phi^2} + \sigma^2 \left[ \sum_{i=0}^{t-1} \phi^{2i} \right] \\
&= \phi^{2t} \frac{\sigma^2}{1-\phi^2} + (1 - \phi^{2t}) \frac{\sigma^2}{1-\phi^2} \\
&= \frac{\sigma^2}{1-\phi^2} [\phi^{2t} + (1 - \phi^{2t})] \\
&= \frac{\sigma^2}{1-\phi^2}
\end{aligned}$$

$$s = 1$$

$$\begin{aligned}
\text{cov}(Y_t, Y_{t+1}) &= \phi^{2t+1} \text{cov}(Y_0, Y_0) + (3) \\
&= \phi^{2t+1} \frac{\sigma^2}{1-\phi^2} + \sigma^2 \left[ \sum_{i=0}^{t-1} \phi^{2i+1} \right] \\
&= \phi^{2t+1} \frac{\sigma^2}{1-\phi^2} + (\phi - \phi^{2t+1}) \frac{\sigma^2}{1-\phi^2} \\
&= \frac{\sigma^2}{1-\phi^2} [\phi^{2t+1} + (\phi - \phi^{2t+1})] \\
&= \phi \frac{\sigma^2}{1-\phi^2}
\end{aligned}$$

$$s = 2$$

$$\begin{aligned}
\text{cov}(Y_t, Y_{t+1}) &= \phi^{2t+2} \text{cov}(Y_0, Y_0) + (3) \\
&= \phi^{2t+2} \frac{\sigma^2}{1-\phi^2} + \sigma^2 \left[ \sum_{i=0}^{t-1} \phi^{2i+2} \right] \\
&= \phi^{2t+2} \frac{\sigma^2}{1-\phi^2} + (\phi^2 - \phi^{2t+2}) \frac{\sigma^2}{1-\phi^2} \\
&= \frac{\sigma^2}{1-\phi^2} [\phi^{2t+2} + (\phi^2 - \phi^{2t+2})] \\
&= \phi^2 \frac{\sigma^2}{1-\phi^2}
\end{aligned}$$

Assim, a fórmula geral para todo  $s \geq 0$ ,

$$\gamma(s) = \text{cov}(Y_t, Y_{t+s}) = \phi^s \frac{\sigma^2}{1-\phi^2}$$

Mostrando assim, que o processo  $\{Y_t\}$  para o caso de  $Y_0 \neq 0$  é estacionário, pois a esperança e as autocovariâncias não dependem de  $t$ .

## 2 Questão 2

Abaixo encontra-se a função implementada no R, com a finalidade de representar o processo analisado na questão 1. A função criada, possui 3 argumentos, **p**, **n** e **s**, em que **p** seria o valor da constante  $\phi$ , **n** o tamanho da série e **s** a variância do ruído branco desejado. A seguir, no código abaixo, seria um processo  $Y_t$  tomando como tamanho da série de 50, e  $\phi = 0.7$ , como pede a questão e foi escolhido para a variância do ruído branco como sendo 1, em que o ruído branco escolhido para o desenvolvimento da função foi uma normal com média 0.

```
R> y<-NULL
R> x<-NULL
R> takehome<-function(p,n,s){
R+   r<-rnorm(n,0,s)
R+   for(j in 1:n){
R+     for(i in 1:j){
R+       x[i]<-p^(i-1)*r[j-(i-1)]
R+     }
R+     y[j]<-sum(x[1:j])
R+   }
R+ y
R+ }
```

Partindo disso, serão criados três gráficos, o gráfico da série gerada, e os gráfico das funções de autorrelação (FAC's) e das funções de autorrelação parciais (FACP's). Abaixo, encontra-se o código utilizado para o desenvolvimentos dos gráficos, e o gráfico em seguida.

```
R> plot.ts(takehome(0.7,50,1), main="", xlab="", ylab="")
```




Figura 2.1: Gráfico da Série.



Analisando o gráfico da série, que encontra-se na Figura 2.1, poderia ser observado o que foi provado teoricamente na primeira questão, se o valor de  $t$  aumentasse, de que o processo  $\{Y_t\}$  é não estacionário, mas quando o valor de  $t$  cresce, ele torna-se estacionário.

```
R> acf(takehome(0.7,50,1), main="FAC's", xlim=c(1,16))
```




Figura 2.2: Gráfico das FAC's.

O gráfico gerado das FAC's, que encontra-se na Figura 2.2, como pode ser observado, apresenta um rápido decaimento exponencial.

```
R> pacf(takehome(0.7,50,1), main="FACP's")
```

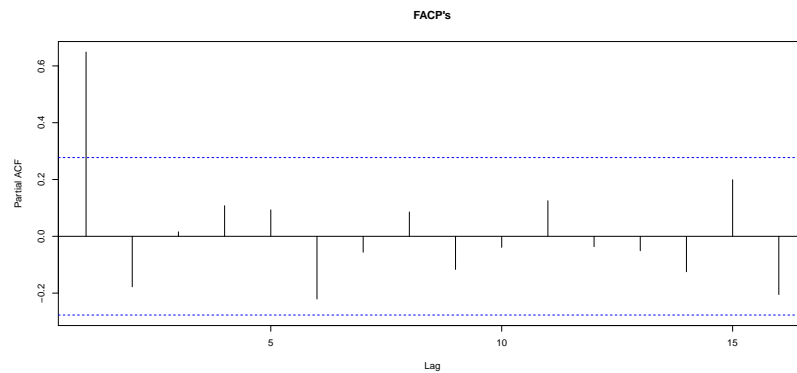


Figura 2.3: Gráfico das FACP's.

O gráfico das FACP's, que encontra-se na Figura 2.3, dá indicativos de que o processo é um processo autoregressivo de primeira ordem, como ficou indicado em uma observação feita na primeira questão.

### 3 Questão 3

Será analisado nesta questão, dados sobre um tipo de investimento chamado BOND, em que os dados são quadrimensais e vão de 1953 até 1970. O arquivo foi disponibilizado em formato do Excel. O objetivo é encontrar um melhor modelo para esta série. O software utilizado para a realização da análise será o R, os códigos utilizados para a análise serão colocados no Anexo I, deste relatório, e abaixo será comentado sobre análises concluídas, a partir dos resultados encontrados.

Inicialmente, foi construído o gráfico da série, que encontra-se na Figura 3.4.




Figura 3.4: Gráfico da Série BOND.

Observando assim, que existe uma tendência na série, então será necessário aplicar uma diferença, para tentar deixar a série livre de tendências. Formando assim, o gráfico abaixo, da Figura 3.5.




Figura 3.5: Gráfico da Série BOND com uma diferença.

Após isso, serão feitos gráficos das FAC's e FACP's, da série após a diferença, para se ter uma melhor noção de como a série funciona, e verificar quais modelos poderiam melhor se ajustar a esta série. Na Figura 3.6 encontram-se os gráficos das FAC's e FACP's.




Figura 3.6: Gráfico das FAC's e FACP's.

Após analisar os gráficos acima, conclui-se que existem três possibilidades de modelos, para a qual a série após tirada uma diferença poderá ser ajustada:

- O gráfico das FAC's sugerem um modelo (médias móveis) MA(1) pois, os lag 1 é o único diferente de 0, e as FACP's aparentam um decaimento exponencial com senóide, indicando um MA(1).
- O gráfico das FACP's sugerem um modelo (autoregressivo) AR(2), pois para os lags  $> 2$  todos os demais valores estão dentro do intervalo de confiança e as FAC's aparentam um decaimento exponencial com senóide.
- Ou uma combinação dos dois modelos, formando um modelo misto (médias móveis integrado com médias móveis) ARMA(2,1).

Ajustando assim aos modelos, MA(1), AR(2) e ARMA(2,1) temos que,

**Pelo Modelo MA(1):**

Após realizado as estimações do coeficientes, encontrou-se o processo abaixo.

$$\hat{Y}_t = 0.0670 + \varepsilon_t + 0.5572\varepsilon_{t-1}$$

Em que todos os coeficientes do modelos apresentam significância, como pode ser observado na Tabela 3.1, em que o intercept, seria o valor do termo constate no modelo MA(1) estimado.

Tabela 3.1: Significâncias dos coeficientes.

	ma1	intercept
significância	9.056494e-08	6.802578e-03

Com relação a análise de resíduos, pelos gráficos da Figura 3.7, tem-se que ao longo do tempo os resíduos não apresentam nenhum padrão aparente e parecem estar aleatoriamente distribuídos ao longo do tempo em torno do zero, e variância constante.

A respeito das FAC's dos resíduos com lag  $\neq 1$  são estatisticamente iguais a zero, indicando que os resíduos são não correlacionados.

E a estatística de Ljung-Box, verifica quanto ao valores-p do teste de hipótese de que os resíduos são não correlacionados, como os valores são altos, a hipótese nula não foi rejeitada.

Será verificado quanto a distribuição dos resíduos, pois se os resíduos apresentarem distribuição normal, a não correlação implicará independência, e alguns testes estatísticos poderam ser utilizados com mais credibilidade.

Realizado o teste de Kolmogorvo-Smirnov para verificação de normalidade, encontrou-se um valor-p de 2.224e-10, o que indica que a hipótese nula de que os resíduos vêm da realização de uma variável aleatória com uma distribuição normal, foi fortemente rejeitada.

### **Pelo Modelo AR(2):**

Após realizado as estimações do coeficientes, encontrou-se o processo abaixo.

$$\hat{Y}_t = 0.05012 + 0.5781\hat{Y}_{t-1} - 0.3173\hat{Y}_{t-2}$$

Em que todos os coeficientes do modelos apresentam significância, como pode ser observado na Tabela 3.2, em que o valor constante no modelo seria o "intercept" que encontra-se na tabela multiplicado por um menos a soma dos demais coeficientes do modelo AR(2) estimado.

Tabela 3.2: Significâncias dos coeficientes.

	ar1	ar2	intercept
significância	4.415847e-06	4.905385e-03	2.144352e-03

Com relação a análise de resíduos, pelos gráficos da Figura 3.7, tem-se que ao longo do tempo os resíduos não apresentam nenhum padrão aparente e parecem estar aleatoriamente distribuídos ao longo do tempo em torno do zero, e variância constante. A respeito

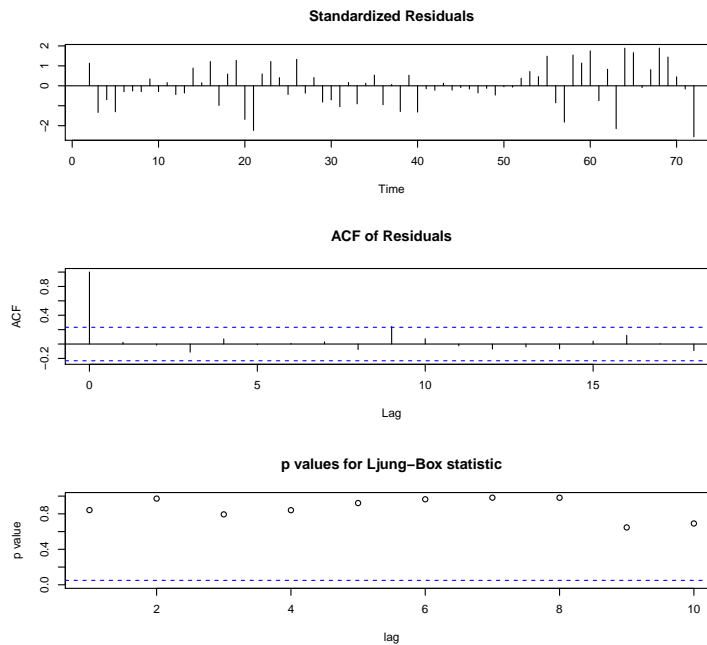


Figura 3.7: Gráficos das Análises de Resíduos.

das FAC's dos resíduos com  $\text{lag} \neq 1$  são estatisticamente iguais a zero, indicando que os resíduos são não correlacionados.

E a estatística de Ljung-Box, verifica quanto ao valores-p do teste de hipótese de que os resíduos são não correlacionados, como os valores são altos, a hipótese nula não foi rejeitada.

Será verificado quanto a distribuição dos resíduos, pois se os resíduos apresentarem distribuição normal, a não correlação implicará independência, e alguns testes estatísticos poderam ser utilizados com mais credibilidade.

Realizado o teste de Kolmogorvo-Smirnov para verificação de normalidade, encontrou-se um valor-p de  $8.462e-10$ , o que indica que a hipótese nula de que os resíduos vêm da realização de uma variável aleatória com uma distribuição normal, foi fortemente rejeitada.

### **Pelo Modelo ARMA(2,1):**

Após realizado as estimações do coeficientes, encontrou-se que todos os coeficientes do modelos não apresentam significância, como pode ser observado na Tabela 3.3. E portanto, irá-se desconsiderar este possível modelo, para modelagem.

### **Comparando os modelos MA(1) e AR(2)**

Assim, temos dois candidatos para modelar a série temporal em questão, os modelos

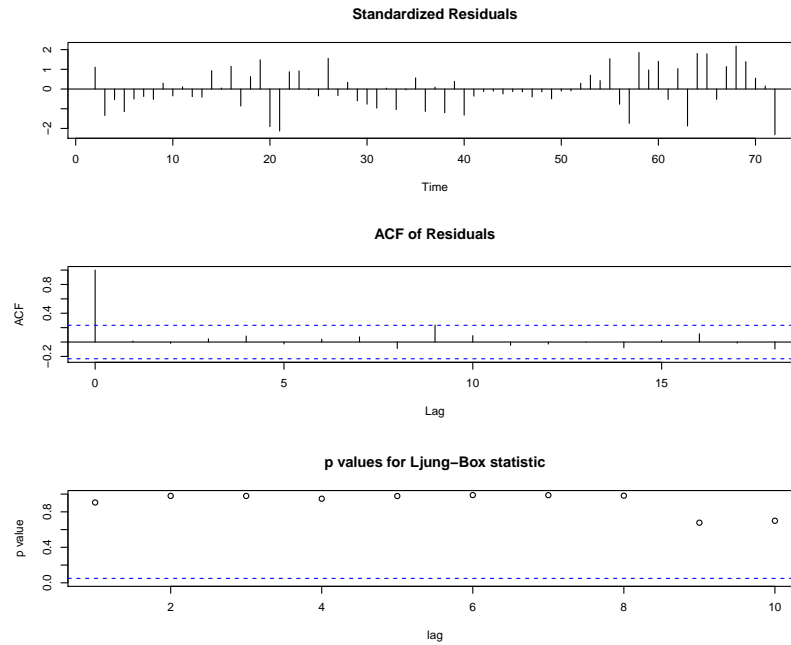


Figura 3.8: Gráficos das Análises de Resíduos.

Tabela 3.3: Significâncias dos coeficientes.

	ar1	ar2	ma1	intercept
significância	0.11774780	0.10990448	0.25035247	0.00332605

MA(1) e AR(2). Serão utilizados três critérios de informação sobre o ajuste do modelo (AIC - Critério de informação de Akaike, BIC - Critério de Informação Bayesiano e FPE - Erro Final de Predição), pra ajudar a escolher o melhor ajuste, já que os parâmetros dos dois modelos foram significativos, e os resíduos possuem mesmas características. A Tabela 3.4 mostra o resultados para cada critério de informação sobre cada modelo. Para a escolha do melhor modelo, com relação a esses critérios, utiliza-se o modelo de menores valores, e portanto o modelo que melhor se ajusta, seria o MA(1). Apesar da diferença ser bem pequena entre os dois modelos quanto a esses critérios, levando em conta o principio da parcimônia, o melhor modelo seria o MA(1) também, pois o modelo possui apenas um parâmetro.

Tabela 3.4: Critérios de informação, AIC, BIC e FPE, sobre o ajuste dos modelos.

	AICn	BICn	FPE
MA(1)	-0.9512322	-0.9273611	0.02217271
AR(2)	-0.9375743	-0.9057462	0.0224571

## 4 Anexo I

### Analizando a série

Leitura dos dados utilizados e gráfico da série.

```
R> bond<-read.csv("F:\\mestrado-ufrn-2015.2016\\ufrn-2015.2\\  
R> series-temporais\\prova-1\\bond.csv", header=T, dec=".", sep=";")  
R> attach(bond)  
R> seriesd<-ts(bond)  
R> plot(seriesd,xlab="Tempo",ylab="Bond",main="")
```

Gráfico da série com uma diferença.

```
R> serie<-diff(seriesd)  
R> plot(serie,xlab="Tempo",ylab="Bond",main="")
```

Gráfico das FAC's e FACP's.

```
R> par(mfrow=c(2,1))  
R> acf(serie,main="",xlab="Lag",ylab="FAC", xlim=c(1,20))  
R> pacf(serie,main="",xlab="Lag",ylab="FACP", xlim=c(1,20))
```

### Ajustando ao modelo MA(1)

```
R> ma1<-arima(serie,order=c(0,0,1))  
R> ma1
```

Call:

```
arima(x = serie, order = c(0, 0, 1))
```

Coefficients:

	ma1	intercept
	0.5572	0.0670
s.e.	0.0960	0.0264

sigma<sup>2</sup> estimated as 0.02067: log likelihood = 36.77, aic = -67.54

Verificando a significância dos coeficientes estimados.

```
R> dp.coef<-sqrt(diag(ma1$var.coef))  
R> t.valor<-ma1$coef/dp.coef  
R> gl<-length(serie)-length(ma1$coef)  
R> valor.p<-pt(abs(t.valor),gl,lower.tail=F) #Valor-p unilateral!  
R> valor.p  
ma1 intercept  
9.056494e-08 6.802578e-03
```

Gráficos dos resíduos ao longo do tempo, as FAC's dos resíduos e o teste de Ljung-Box para vários lags.

```
R> tsdiag(ma1)
```

Verificação de normalidade dos resíduos.

```
R> ks.test(ma1$residuals,"pnorm")
```

One-sample Kolmogorov-Smirnov test

```
data: ma1$residuals
D = 0.3927, p-value = 2.224e-10
alternative hypothesis: two-sided
```

### Ajustando ao modelo AR(2)

```
R> ar2<-arima(serie,order=c(2,0,0))
```

```
R> ar2
```

Call:

```
arima(x = serie, order = c(2, 0, 0))
```

Coefficients:

	ar1	ar2	intercept
	0.5781	-0.3173	0.0678
s.e.	0.1203	0.1194	0.0229

sigma^2 estimated as 0.02036: log likelihood = 37.28, aic = -66.57

Verificando a significância dos coeficientes estimados.

```
R> dp.coef<-sqrt(diag(ar2$var.coef))
```

```
R> t.valor<-ar2$coef/dp.coef
```

```
R> gl<-length(serie)-length(ar2$coef)
```

```
R> valor.p<-pt(abs(t.valor),gl,lower.tail=F) #Valor-p unilateral!
```

```
R> valor.p
```

	ar1	ar2	intercept
	4.415847e-06	4.905385e-03	2.144352e-03

Gráficos dos resíduos ao longo do tempo, as FAC's dos resíduos e o teste de Ljung-Box para vários lags.

```
R> tsdiag(ar2)
```



Verificação de normalidade dos resíduos.

```
R> ks.test(ar2$residuals,"pnorm")
```

One-sample Kolmogorov-Smirnov test

```
data: ar2$residuals
D = 0.3815, p-value = 8.462e-10
alternative hypothesis: two-sided
```

**Ajustando ao modelo ARMA(2,1)**

```
R> arma21<-arima(serie,order=c(2,0,1))
```

```
R> arma21
```

Call:

```
arima(x = serie, order = c(2, 0, 1))
```

Coefficients:

	ar1	ar2	ma1	intercept
	0.3837	-0.2345	0.2157	0.0675
s.e.	0.3206	0.1893	0.3185	0.0241

sigma<sup>2</sup> estimated as 0.02024: log likelihood = 37.48, aic = -64.97

Verificando a significância dos coeficientes estimados.

```
R> dp.coef<-sqrt(diag(arma21$var.coef))
R> t.valor<-arma21$coef/dp.coef
R> gl<-length(serie)-length(arma21$coef)
R> valor.p<-pt(abs(t.valor),gl,lower.tail=F) #Valor-p unilateral!
R> valor.p
```

	ar1	ar2	ma1	intercept
	0.11774780	0.10990448	0.25035247	0.00332605

**Cálculo dos critérios de informação, AIC, BIC e FPE.**

```
R> csm<-function(objeto)
R+ {
R+ aicn<-AIC(objeto,k=2)/length(objeto$res)
R+ bicn<-AIC(objeto,k=log(length(objeto))) /length(objeto$res)
R+ EQM<-objeto$sigma2*length(objeto$resid)/
R+ (length(objeto$resid)-length(objeto$coef))
```

```

R+ fpe<-EQM*(1+(length(objeto$coef)+1)/length(objeto$resid))
R+ saida<-matrix(c(aicn,bicn,fpe),byrow=T,nrow=1,
R+ dimnames=list(c("Valor"),c("AICn","BICn","FPE")))
R+ saida
R+ }
R>
R> csm(ma1)
           AICn          BICn          FPE
Valor -0.9512322 -0.9273611 0.02217271
R>
R> csm(ar2)
           AICn          BICn          FPE
Valor -0.9375743 -0.9057462 0.0224571

```